

P R E Z A N T I M

Assistant over internal documents

*Një sistem RAG që lexon dokumentet e brendshme dhe përgjigjet me burim —
jo me hamendje.*

Gjashtë fazat e projektit

01

Problemi

Identifikimi i nevojës dhe qëllimit të projektit.

02

Planifikimi

Aktorët,dhe fazat që do ndiqen.

03

Analiza

Teknologjitë, arkitektura,kerkesat e projektit dhe flow-i i sistemit.

04

Dizajni

Struktura e ndërfaqes së përdoruesit.

05

Zhvillimi

Implementimi real i sistemit.

06

Testimi

Verifikimi që sistemi funksionon si duhet.

Identifikimi i Problemit

Çfarë është assistant over internal documents?

Një sistem RAG =Retrieval-Augmented Generation që lejon ngarkimin e dokumenteve të brendshme si PDF, Markdown dhe pyetje mbi to në gjuhë natyrale. *Përgjigjet nuk shpiken nga modeli por mbështeten direkt në pjesë specifike të dokumenteve me burimit.*

Pse une e krijova?

E krijova për të ndihmuar punonjësit të gjejnë shpejt informacionin në dokumentet e kompanisë. Sistemi përdor RAG për të dhënë përgjigje të sakta, të bazuara në dokumente dhe me burim të verifikueshëm, duke reduktuar gabimet dhe konfuzionin mes versioneve

Problemet e identifikuara:

A

Informacion i shpërndarë

Punonjësit humbin kohë duke kërkuar nëpër shumë dokumente.

B

Konflikte mes versioneve

Ndryshojne dokumentave ne baze te viteve.

C

Mungesë te dhenash

Nuk dihet nga cili dokument/version vjen përgjigja.

Planifikimi

Aktorët e projektit:

Zhvilluesi Analizë, dizajn, zhvillim, testim

Perdoruesit Ngarkon dokumente, bën pyetje

Administrator dokumentesh Menaxhon versionet

Kerkesat e projektit:

Frontend:

1. Mundësi për ngarkimin e dokumenteve PDF dhe Markdown.
2. Kuti kërkimi/chat-i për të bërë pyetje.
3. Shfaqja e përgjigjes së bashku me dokumentin burim, pjesën përkatëse të tekstit dhe datën/versionin.

Backend:

4. Ruajtja e dokumenteve origjinale.
5. Nxjerrja dhe ndarja e tekstit në pjesë (chunks).
6. Krijimi dhe ruajtja e embeddings me metadata.
7. Kërkimi i pjesëve më të përshtatshme për çdo pyetje.
8. Gjenerimi i përgjigjeve vetëm nga informacioni i gjetur në dokumente.
9. Ruajtja e versionit dhe datës për çdo pjesë të dokumentit.
10. Identifikimi i konflikteve midis versioneve të ndryshme.
11. Shfaqja e burimeve të ndryshme kur dokumentet japin përgjigje kontradiktore.
12. Mundësia për të shënuar një dokument si të vjetëruar dhe për ta përjashtuar nga përgjigjet e ardhshme.

Analiza — Teknologjitë

KOMPONENTI	TEKNOLOGJIA	PËRSHKRIMI
Backend	FastAPI	Dokumentim automatik, Python modern
Frontend	React + TypeScript	Frontend interaktiv, të organizuar dhe të sigurt
Stilimi	Tailwind CSS	Pamje profesionale
Embeddings	Gemini embedding-001	Kthen tekstin në vektorë, falas
LLM	Gemini 3.6-flash	Gjeneron përgjigjet finale, i shpejtë
Vector DB	ChromaDB	Ruan vektorët e dokumenteve, i integruar (embedded), pa server shtesë
Metadata DB	SQLite	E lehtë, zero konfigurim
Ekstraktim teksti	pdfplumber	Trajton layout komplekse PDF
Chunk	tiktoken	Numërim i saktë i token-ave

Arkitektura dhe Flow-i i Sistemit



Rrjedha e punës


- 01 Ngarkimi I PDF/Markdown → ekstraktim teksti → ndarje në chunks
- 02 Çdo chunk → embedding (Gemini) → ruhet në ChromaDB; metadata → SQLite
- 03 Pyetja =kërkohen chunks më të ngjashme në ChromaDB
- 04 Chunks relevante → Gemini si kontekst → përgjigje e bazuar në to
- 05 Frontendi shfaq përgjigjen bashkë me burimet

Dizajni

Ndërfaqja përbëhet nga dy pamje kryesore, të aksesueshme nga një navbar i thjeshtë.


Documents

Zona e ngarkimit të dokumenteve (drag-and-drop) dhe menaxhimi i tyre — versionim, shënim si i vjetëruar, fshirje.



Chat

Fusha e bisedës ku përdoruesi shkruan pyetje dhe merr përgjigje me burime të cituara.



Zhvillimi

Çfarë u implementua

- 01

Backend (FastAPI)
Endpoints për dokumente dhe chat
- 02

Procesim dokumentesh
Ekstraktim teksti + ndarje në chunks
- 03

Integrim me Gemini
Embeddings dhe gjenerim përgjigjesh
- 04

Ruajtje të dhënash
SQLite (metadata) + ChromaDB (vektorë)
- 05

Frontend (React+TS+Tailwind)
Dy pamje: Chat dhe Documents

Endpoints kryesore të API-t

POST	/api/documents/upload	Ngarkon PDF/Markdown
GET	/api/documents	Liston dokumentet
PATCH	/api/documents/{id}	Përditëson (outdated)
DELETE	/api/documents/{id}	Fshin dokumentin
POST	/api/chat	Bën një pyetje
GET	/api/health	Statusi i sistemit

Testimi

Ngarkimi I dokumentave:

All Bo

Doc Assistant

ChatDocuments

Documents

Upload and manage your internal documents

Drag & drop a PDF or Markdown file, or click to browse

Supported: .pdf, .md

DOCUMENT	TYPE	VERSION	CHUNKS	STATUS	UPLOADED	ACTIONS
company-policy-2024.md	MD	v1	2	Active	8/26/2026	
company-policy-2025.md	MD	v1	2	Active	8/26/2026	

Kur behet dokumenti I vjeteruar:

company-policy-2025.md

MD

v1

2

Outdated

8/26/2026

Testimi

 All Bookmarks

 Doc Assistant  Chat  Documents

Sa ditë pune nga shtëpia lejohen në javë?

Punonjësit lejohen të punojnë në distancë deri në 2 ditë në javë [company-policy-2024.md, v1].

^ 2 sources

 **company-policy-2024.md** v1 75%
Uploaded: 8/26/2026 · Chunk #0
Manuali i Politikave të Kompanisë 2024
Politika e Punës në Distancë
...
[Show more](#)

 **company-policy-2024.md** v1 65%
Uploaded: 8/26/2026 · Chunk #1

 Doc Assistant  Chat  Documents

A kërkohet miratimi i menaxherit për punën në distancë?

 **Potential conflict detected between sources**

Kërkesa për miratimin e menaxherit për punën në distancë ndryshon sipas dokumenteve të politikave të kompanisë:

* **Politika e vitit 2024:** Puna në distancë duhet të miratohej nga menaxheri i drejtpërdrejtë të paktën 48 orë përpara [company-policy-2024.md, v1].

* **Politika e vitit 2025 (I përditësuar):** Puna në distancë nuk kërkon më miratim paraprak nga menaxheri [company-policy-2025.md, v1].

^ 4 sources

 **company-policy-2024.md** v1 74%
Uploaded: 8/26/2026 · Chunk #0

Faleminderit!